

Presentación de propuesta de Investigación

Proponentes: Dorian Joseph Esguerra Perilla, Kevin Daniel Arango Algarra

Código estudiantil: 831244, 751148

Programa: Ingeniería de Sistemas.

Director Propuesto: Carlos Armando López Solano, MSc.

Departamento: N/A

Asesores: N/A

Título: Desarrollo de una arquitectura de agentes de IA para la detección de flujos de capital privilegiado y optimización de decisiones en mercados volátiles.

Área: Inteligencia Artificial y Ciencia de Datos.

Línea de Investigación: Innovaciones sociales y productivas.

Antecedentes y Justificación

El presente proyecto surge de la necesidad de replantear el uso de la Inteligencia Artificial en los mercados financieros, desplazando el enfoque tradicional de la 'predicción absoluta' hacia la optimización estadística de la ventaja competitiva. En el contexto de un sistema financiero global caracterizado por la opacidad y la alta frecuencia, el trader minorista se encuentra en una desventaja estructural. Esta iniciativa se propone como un sistema de 'Minería de Ventajas', donde se analiza gráficos de precios y se procesa señales de alta fidelidad provenientes de fuentes no convencionales

El panorama financiero actual ha mutado hacia la descentralización. Los mercados de predicción (como Polymarket y Kalshi) han movido más de 44 mil millones de dólares en 2025, demostrando ser indicadores más precisos que las encuestas tradicionales. Sin embargo, el trader minorista sigue operando con una asimetría de información crítica.

Investigaciones recientes de Anthropic han demostrado que arquitecturas de IA bien estructuradas pueden alcanzar un 68.4% de efectividad (Win Rate) en estos mercados. Al combinar esto con la transparencia de la Blockchain, hoy es posible rastrear flujos de capital de "Smart Money" o carteras vinculadas a figuras con información privilegiada (insider trading), transformando datos públicos pero dispersos en una ventaja estadística ejecutable.

flujos de capital en la blockchain, movimientos de figuras con información privilegiada (insider tracking) y mercados de predicción descentralizados. El objetivo es transformar la IA en una herramienta de 'transparencia forzada', permitiendo que grupos de investigación y pequeños inversores operen con un nivel de inteligencia de datos que, hasta hace poco, era patrimonio exclusivo de los grandes fondos de cobertura.

Identificación del problema:

Diversos estudios académicos han demostrado que los inversores minoristas presentan pérdidas sistemáticas en sus operaciones (Barber et al., 2009; Barber et al., 2023), mientras que datos regulatorios recientes indican que más del 90% de los traders minoristas pierden dinero en mercados derivados (SEBI, 2024).

Aproximadamente un 90% de los traders minoristas pierden capital debido a tres factores:

Asimetría Tecnológica e Informativa: Mientras las instituciones operan con algoritmos de alta frecuencia y acceso a datos procesados, el minorista depende de información rezagada y herramientas de análisis técnico básico que ya han sido descontadas por el mercado.

La Ilusión de la Predicción Humana: El cerebro humano no está diseñado para procesar la aleatoriedad de los mercados. Los sesgos cognitivos (miedo, avaricia, exceso de confianza) llevan a una gran cantidad de los operadores a tomar decisiones emocionales, mientras que los grandes actores explotan precisamente esa predictibilidad del error humano.

Saturación de "Ruido" sobre "Señal": En la era de la sobreinformación, el trader minorista es incapaz de distinguir entre el ruido mediático y la señal real de valor (como el flujo de capital de insiders o movimientos en mercados de predicción). Sin un sistema de filtrado inteligente, el usuario promedio está operando, estadísticamente, con una probabilidad de éxito inferior al azar.

Objetivo general:

Desarrollar y optimizar una arquitectura de trading algorítmico basada en agentes de IA, que integre el análisis de flujos de capital privilegiado (insider tracking) y modelos de aprendizaje automático avanzado, con el fin de superar el umbral del 68% de efectividad en la toma de decisiones dentro de mercados de predicción y activos volátiles.

Objetivos Específicos:

- Refinamiento de Capacidades mediante Fine-Tuning y RAG: Entrenar capas específicas del modelo con conjuntos de datos históricos de "Smart Money" y resultados reales de mercados de predicción para ajustar la interpretación de señales financieras que los modelos genéricos suelen pasar por alto.
- Arquitectura de Prompt Engineering Multimodal: Diseñar un sistema de Chain-of-Thought (Cadena de Pensamiento) que obligue a la IA a contrastar la información pública con los movimientos detectados en la blockchain (insider tracking) antes de emitir una probabilidad de éxito.
- Integración de Agentes de Verificación Externa: Desarrollar "Skills" adicionales que permitan a la IA realizar búsquedas autónomas en tiempo real para validar la veracidad de los eventos analizados, mitigando alucinaciones y sesgos informativos.
- Optimización de la Gestión de Riesgo Probabilístico: Implementar algoritmos de dimensionamiento de posición (como el Criterio de Kelly) que se ajusten dinámicamente según el nivel de confianza reportado por la IA tras su proceso de fine-tuning y dependiendo de los datos obtenidos gracias al RAG.
- Diseñar un marco de evaluación comparativa (Benchmarking): Contrastar el desempeño del sistema desarrollado frente a estrategias de trading convencionales y modelos de IA base, utilizando entornos de simulación de alta fidelidad para validar la reducción del riesgo y el aumento en la tasa de acierto.

Metodología:

1: Agente de trading y Liquidez (Market Scanner): Implementación de un algoritmo que filtre activos basándose en volumen, liquidez y tiempo de resolución. Su función principal será detectar anomalías en los diferenciales de precios (spreads) que indiquen ineficiencias explotables.

2: Agente de Investigación OSINT y Blockchain Forensics: Despliegue de agentes especializados en scraping de fuentes masivas (X, Reddit, RSS). Estos realizarán un análisis de sentimiento multivariable para contrastar la narrativa social contra las probabilidades reales del mercado, identificando divergencias donde el mercado esté sobre-reaccionando o ignorando eventos clave.

Este agente incorporará un módulo de monitoreo de 'Smart Money' e 'Insider Tracking' gracias a un proceso RAG. Mediante el análisis de libros contables públicos (Blockchain), el sistema rastreará carteras digitales vinculadas históricamente a figuras con alta tasa de acierto en temas regulatorios o políticos (ej. cuentas asociadas a miembros de gabinetes o congresistas en plataformas como Polymarket). Al detectar un flujo de capital inusual de estos actores antes de un anuncio oficial, el agente categoriza esta señal como 'Evidencia de Información Privilegiada', dándole prioridad sobre el sentimiento general de redes sociales como Twitter o Reddit.

3: Agente de Predicción (LLM + XGBoost) Desarrollo de un modelo que combine la capacidad de razonamiento lógico de un LLM (mediante Prompt Engineering avanzado) con la precisión estadística de XGBoost. Este agente solo emitirá una señal de ejecución cuando la confianza estadística supere un umbral de seguridad predefinido.

El modelo de predicción no solo evaluará la narrativa pública, sino que utilizará los datos del rastreo de insiders como una variable de alta fidelidad (High-Confidence Feature). Si el análisis de sentimiento de la prensa es neutral, pero el módulo de rastreo detecta compras masivas por parte de carteras estratégicas, el algoritmo ajustará la probabilidad de éxito al alza. El sistema está diseñado para identificar divergencias: cuando el 'insider' opera en dirección opuesta a la opinión pública, el modelo asignará un peso estadístico mayor a la acción del capital sobre la narrativa mediática.

4: Gestor de Riesgo y Optimización de Capital: Implementación de un agente basado en criterios de gestión de banca (Bankroll Management) y el Modelo de Kelly. Este evaluará el "Edge" (ventaja) de cada operación y bloqueará aquellas que representen un riesgo asimétrico para la cuenta, ejecutando únicamente las que cumplan con el ratio riesgo-beneficio óptimo.

5: Sistema de Aprendizaje Post-Mortem y Retroalimentación: Creación de un ciclo de auditoría compuesto por 5 agentes que analicen cada pérdida. Su objetivo es identificar si el error fue de datos, de lógica o de mercado, actualizando la base de conocimientos del sistema para prevenir la repetición de fallos sistémicos.

Síntesis de metodología

Fase 1: Recolección de datos (mercado + on-chain) Limpieza y estructuración

Fase 2: Feature engineering

Fase 3: Modelo base (ej: XGBoost)

Fase 4: Comparación con modelo IA (LLM + RAG)

Fase 5: Backtesting

Fase 6: Evaluación estadística

Fuentes de Datos (Dataset)

El dataset para el desarrollo del modelo estará compuesto por la integración progresiva y modular de múltiples fuentes de información financiera y alternativa, con el objetivo de capturar distintas dimensiones del comportamiento del mercado.

En una primera fase, se emplearán datos históricos de mercado (OHLCV: Open, High, Low, Close, Volume) obtenidos a través de APIs públicas de exchanges como Binance. Estos datos constituirán la base estructural del modelo, permitiendo el análisis de precios, volumen y la construcción de indicadores técnicos.

Posteriormente, se incorporarán datos on-chain provenientes de plataformas especializadas como Glassnode o CryptoQuant, los cuales permiten analizar el comportamiento de grandes participantes del mercado, flujos de capital y métricas relevantes de red en activos digitales. La inclusión de esta fuente será evaluada en función de su impacto en el desempeño del modelo.

Adicionalmente, se integrarán datos de sentimiento del mercado mediante el uso de APIs de plataformas como Reddit, con el fin de capturar dinámicas de comportamiento colectivo, tendencias emergentes y posibles eventos de alta volatilidad. Estos datos serán procesados mediante técnicas de análisis de lenguaje natural para su transformación en variables cuantificables.

Como complemento, se considerarán datos regulatorios públicos, específicamente reportes de operaciones de insiders publicados por la Securities and Exchange Commission (SEC), los cuales serán utilizados como variables contextuales de baja frecuencia, sin constituir el eje central del modelo predictivo.

Finalmente, se podrán incorporar fuentes de noticias financieras mediante APIs o feeds RSS, con el objetivo de incluir eventos macroeconómicos y noticias relevantes que puedan influir en el comportamiento del mercado.

La integración de las distintas fuentes se realizará de manera progresiva, evaluando el impacto incremental de cada tipo de dato mediante experimentos controlados. Todos los datos serán sincronizados temporalmente y sometidos a procesos de limpieza, normalización y validación, con el fin de garantizar su coherencia y calidad para su uso en modelos de aprendizaje automático.

Actividades para desarrollar:

1. Revisión bibliográfica y estado del arte sobre modelos de predicción en mercados financieros, uso de machine learning y datos alternativos.
2. Definición del alcance del proyecto, variables de estudio y selección de activos financieros a analizar.
3. Recolección de datos históricos de mercado (OHLCV) mediante APIs públicas.
4. Implementación del proceso de limpieza, transformación y sincronización temporal de los datos.
5. Diseño e implementación de características (feature engineering) a partir de datos de mercado.
6. Desarrollo de un modelo base de predicción utilizando técnicas de machine learning (por ejemplo, XGBoost).
7. Evaluación inicial del modelo base mediante métricas de desempeño (accuracy, precision, recall, Sharpe ratio, drawdown).
8. Integración progresiva de datos on-chain y evaluación de su impacto en el modelo.

9. Integración de datos de sentimiento (Reddit) y procesamiento mediante técnicas de NLP.
10. Incorporación de datos de noticias y eventos relevantes del mercado.
11. Comparación del desempeño entre modelos con distintas combinaciones de fuentes de datos.
12. Implementación de un esquema de gestión de riesgo basado en el criterio de Kelly o variantes conservadoras.
13. Desarrollo de un sistema de backtesting para validar el desempeño del modelo en escenarios históricos.
14. Análisis de resultados, validación estadística y discusión de hallazgos.
15. Documentación del proyecto y redacción del informe final.
16. Preparación de la sustentación y presentación del proyecto.

Cronograma:

Tiempo	Actividad
Meses 1–2	Revisión bibliográfica Definición del alcance y diseño del proyecto
Meses 3–4	Recolección de datos de mercado Limpieza y estructuración inicial
Meses 5–6	Feature engineering Desarrollo del modelo base (XGBoost)
Meses 7–8	Evaluación del modelo base Implementación de backtesting
Meses 9–10	Integración de datos on-chain Evaluación comparativa
Meses 11–12	Integración de datos de sentimiento (Reddit) Procesamiento NLP
Meses 13–14	Integración de noticias Ajustes finales del modelo
Meses 15–16	Implementación de gestión de riesgo (Kelly) Evaluación final del sistema
Meses 17–18	Análisis de resultados Redacción del documento final Preparación de sustentación

Infografía:

Arquitectura del Sistema de Trading Algorítmico basado en IA

Flujo de datos y toma de decisiones del modelo



Entrada de Datos

- Datos de mercado (OHLCV)
- Datos on-chain
- Datos de sentimiento (Reddit)
- Noticias financieras
- Datos regulatorios (SEC)



Procesamiento

- Limpieza de Datos
- Normalización
- Filtrado de Ruido
- Detección de Anomalías



Feature Engineering

- Indicadores técnicos
- Variables on-chain
- Análisis de sentimiento (NLP)



Modelos

- Modelo base (XGBoost)
- Modelo avanzado (LLM + RAG)



Toma de Decisiones

- Probabilidad de éxito
- Señales (Buy / Sell / Hold)



Gestión de Riesgo

- Bankroll Management
- Criterio de Kelly



Evaluación

- Backtesting
- Análisis de Rendimiento
- Mejora Continua
- Métricas Clave (ROI, Sharpe)

Costos del trabajo y fuentes de financiación:

El desarrollo del proyecto se plantea bajo un enfoque de bajo costo, utilizando principalmente herramientas y fuentes de datos de acceso gratuito.

Costos estimados:

- Infraestructura computacional: uso de equipo personal o servicios gratuitos como Google Colab.
- APIs de datos de mercado (Binance, Yahoo Finance): sin costo.
- API de Reddit: acceso gratuito con limitaciones.
- Datos on-chain: uso de versiones gratuitas de plataformas como Glassnode o CryptoQuant (con limitaciones).
- Herramientas de desarrollo: software libre (Python, bibliotecas de machine learning).

Costos potenciales (opcionales):

- Suscripciones a APIs premium de datos financieros.
- Mejora de infraestructura (GPU en la nube).
- Acceso a datasets especializados.

Fuentes de financiación:

- Recursos propios del estudiante.
- Infraestructura proporcionada por la institución educativa.
- Uso de herramientas y plataformas gratuitas disponibles en la nube.

Bibliografía

Barber, B. M., Lee, Y. T., Liu, Y. J., & Odean, T. (2009)
Just How Much Do Individual Investors Lose by Trading?
The Review of Financial Studies.

Demuestra que los inversores individuales pierden dinero de forma sistemática.
https://papers.ssrn.com/sol3/papers.cfm?abstract_id=529062

Barber, B. M., Lin, S., & Odean, T. (2023)
Resolving a Paradox: Retail Trades Positively Predict Returns but Are Not Profitable
Journal of Financial and Quantitative Analysis / SSRN.
Concluye que, en promedio, las operaciones de inversores minoristas no son rentables.

https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3783492

Estudios empíricos y regulatorios (datos reales de mercado)
Securities and Exchange Board of India (SEBI) (2024)
Analysis of retail traders in derivatives markets
Aproximadamente 93% de traders minoristas pierden dinero en F&O.

https://timesofindia.indiatimes.com/business/india-business/over-9-in-10-fo-retail-traders-lose-money-sebi/articleshow/113613126.cms?utm_source=chatgpt.com

Kandadi, T., & Shankarlingam, G. (2024)
Analysis Report of Traders Losing Money in Trading Platforms (SSRN)

Analiza patrones de pérdidas en traders minoristas post-COVID.

https://papers.ssrn.com/sol3/papers.cfm?abstract_id=5000105

Estudios sobre comportamiento y psicología del trading
Liu, Y. Y., et al. (2014)
Prospect Theory for Online Financial Trading
Analiza millones de operaciones y demuestra sesgos como aversión a la pérdida.

https://arxiv.org/abs/1402.6393?utm_source=chatgpt.com

Shahtahmassebi, G., & Wright, L. (2021)
Profit and Loss Manipulations by Online Trading Brokers

Sugiere que hasta un 82% de traders pierde dinero, incluyendo factores estructurales.

https://arxiv.org/abs/2107.14055?utm_source=chatgpt.com

Firma de los proponentes

Kevin Daniel Arango Alguina

Faty Theos