

CORPORACIÓN UNIVERSITARIA MINUTO DE DIOS

Ingeniería de Sistemas

Semillero de Investigación Sophia

**Desarrollo y evaluación de una arquitectura híbrida basada
en XGBoost y modelos de lenguaje para apoyar decisiones de
trading y gestión de riesgo en mercados volátiles**

Documento de investigación capítulos 1 a 3

Dorian Joseph Esguerra Perilla
Código estudiantil 831244

Kevin Daniel Arango Algarra
Código estudiantil 751148

Director Carlos Armando López Solano MSc

Bogotá 2026

Contenido

Capítulo 1 Introducción

- 1.1 Contextualización del problema
- 1.2 Formulación del problema
- 1.3 Pregunta de investigación
- 1.4 Objetivos
- 1.5 Hipótesis
- 1.6 Justificación
- 1.7 Alcance y limitaciones

Capítulo 2 Marco teórico y estado del arte

- 2.1 Antecedentes
- 2.2 Bases teóricas
- 2.3 Definición de términos

Capítulo 3 Metodología

- 3.1 Tipo y diseño de investigación
- 3.2 Arquitectura propuesta
- 3.3 Datos y variables
- 3.4 Procedimiento experimental
- 3.5 Protocolo de evaluación
- 3.6 Reproducibilidad y trazabilidad
- 3.7 Consideraciones éticas
- 3.8 Amenazas a la validez

Capítulo 1 Introducción

Los mercados financieros producen series temporales de precios y volumen, junto con flujos continuos de información textual. Esta combinación plantea un problema de ingeniería: integrar datos heterogéneos sin perder trazabilidad temporal y evaluar si su uso mejora una decisión bajo incertidumbre. Un modelo puede clasificar correctamente parte de los movimientos y aun así fallar como estrategia debido a costos, probabilidades mal calibradas o pérdidas de gran magnitud.

Nostradamus V2 se formula como una arquitectura experimental compuesta por un cerebro cuantitativo, un componente cualitativo y un árbitro de riesgo. El cerebro cuantitativo utiliza XGBoost para estimar la probabilidad de una variación favorable en un horizonte definido. El componente cualitativo clasifica el sentimiento de titulares publicados antes de la decisión. El árbitro aplica reglas deterministas para aprobar, rechazar o abstenerse y para limitar la exposición.

La investigación se concentra en evaluar el sistema, no en prometer rentabilidad. El diseño comparará configuraciones progresivas para establecer si el sentimiento y la gestión de riesgo aportan una mejora fuera de muestra frente a modelos más simples. La evaluación combinará métricas de aprendizaje automático, calibración probabilística y desempeño financiero.

1.1 Contextualización del problema

El inversor minorista opera con restricciones de tiempo, infraestructura y acceso a información procesada. Las decisiones pueden estar afectadas por ruido, sesgos cognitivos y una interpretación incompleta de eventos recientes. La automatización puede ayudar a ordenar evidencia y aplicar reglas consistentes, pero también puede amplificar errores si el modelo fue evaluado con información futura, si se optimizó sobre el mismo periodo que se reporta o si se ignoran costos de ejecución.

En finanzas, la precisión de clasificación no equivale a rentabilidad. Una estrategia con pocas pérdidas de gran tamaño puede tener un win rate alto y un resultado económico negativo. Por esta razón, el proyecto separa tres problemas: estimar una probabilidad, contextualizar la señal y controlar el riesgo. Cada problema se evaluará con métricas propias y mediante una comparación incremental.

1.2 Formulación del problema

El prototipo inicial de Nostradamus V2 integra datos OHLCV, características técnicas, XGBoost, análisis de titulares y criterio de Kelly. No obstante, una integración funcional no demuestra que el sistema generalice ni que la complejidad adicional mejore el desempeño. Se requiere un protocolo que preserve el orden temporal, calibre probabilidades, simule costos y compare alternativas bajo las mismas condiciones.

El problema central consiste en determinar si la combinación de señales cuantitativas y cualitativas mejora el desempeño fuera de muestra y si una política de riesgo reduce pérdidas sin eliminar la posible ventaja del modelo. El análisis debe distinguir entre mejora estadística y mejora económica, y debe registrar las condiciones en las que los resultados cambian.

1.3 Pregunta de investigación

¿En qué medida la integración de un modelo XGBoost, una señal de sentimiento derivada de titulares financieros y una política determinista de gestión de riesgo mejora el desempeño fuera de muestra frente a un modelo exclusivamente cuantitativo y frente a estrategias de referencia en mercados volátiles?

1.4 Objetivos

1.4.1 Objetivo general

Desarrollar y evaluar una arquitectura híbrida basada en XGBoost, análisis de sentimiento y gestión probabilística de riesgo para apoyar decisiones de trading en mercados volátiles mediante experimentos reproducibles y backtesting temporal.

1.4.2 Objetivos específicos

- Construir un pipeline reproducible de adquisición, validación y transformación de datos OHLCV.
- Diseñar características técnicas y una variable objetivo sin fuga de información futura.
- Entrenar y calibrar un modelo XGBoost como línea base cuantitativa.
- Obtener una señal de sentimiento estructurada a partir de titulares disponibles antes de cada decisión.
- Diseñar una política de riesgo determinista con estados operar, no operar y abstenerse.
- Implementar backtesting walk-forward con costos, slippage y comparaciones controladas.
- Cuantificar el aporte de cada componente mediante experimentos de ablación y análisis de sensibilidad.

1.5 Hipótesis

H1. La arquitectura híbrida mejora al menos una métrica financiera ajustada por riesgo fuera de muestra, sin un deterioro material del máximo drawdown, frente al modelo XGBoost utilizado de forma aislada.

H0. La incorporación del sentimiento y de la política de riesgo no mejora de forma consistente el desempeño frente al modelo XGBoost bajo el mismo periodo, horizonte y estructura de costos.

La hipótesis no establece un porcentaje de acierto obligatorio. La aceptación o rechazo dependerá de resultados repetibles en ventanas temporales y de la magnitud observada frente a la variabilidad de las métricas.

1.6 Justificación

1.6.1 Justificación técnica

El proyecto integra ingeniería de datos, aprendizaje supervisado, procesamiento de lenguaje natural, evaluación temporal y gestión de riesgo. La arquitectura modular permite sustituir componentes y medirlos por separado. La decisión final se mantiene determinista para evitar que un modelo de lenguaje controle directamente el capital asignado.

1.6.2 Justificación académica

El aporte académico se encuentra en el diseño comparativo. El estudio documentará si el sentimiento aporta información incremental, si la calibración modifica el dimensionamiento y si la gestión de riesgo mejora la relación entre retorno y pérdida. Un resultado sin mejora también será relevante porque permitirá identificar componentes que agregan complejidad sin beneficio estable.

1.6.3 Justificación económica y social

La solución utiliza herramientas de código abierto y fuentes de acceso público, por lo que puede desarrollarse con infraestructura limitada. Como prototipo educativo, promueve decisiones trazables y controles de riesgo. No sustituye la asesoría profesional ni garantiza beneficios.

1.7 Alcance y limitaciones

El alcance cubre datos históricos, entrenamiento y evaluación de modelos, análisis de titulares, backtesting y paper trading. No incluye ejecución real, conectividad con brokers, negociación de alta frecuencia ni detección de información no pública. Las conclusiones estarán limitadas a los activos, periodos, frecuencias, costos y fuentes analizados.

Elemento	Alcance
Mercado	Activos líquidos disponibles mediante fuentes públicas
Frecuencia	Datos diarios en la primera versión experimental
Predicción	Dirección del retorno para un horizonte definido
Texto	Titulares con fecha y fuente verificables
Ejecución	Backtesting y paper trading
Uso	Investigación y apoyo a decisiones, sin recomendación financiera

Capítulo 2 Marco teórico y estado del arte

2.1 Antecedentes

La aplicación de aprendizaje automático a finanzas se ha orientado a modelar relaciones no lineales, seleccionar variables y producir pronósticos fuera de muestra. Gu, Kelly y Xiu reportan que los métodos basados en árboles y redes pueden capturar interacciones relevantes en problemas de valoración de activos, aunque su utilidad depende del diseño empírico y del control de complejidad.

Chen y Guestrin presentaron XGBoost como un sistema escalable de tree boosting. Su regularización y capacidad para representar interacciones lo convierten en una alternativa razonable para una línea base tabular. En este proyecto, XGBoost no se considera una fuente autónoma de verdad; se utiliza como estimador cuya probabilidad debe evaluarse y calibrarse.

El análisis de sentimiento financiero busca transformar lenguaje especializado en variables cuantificables. FinBERT mostró la ventaja de adaptar modelos preentrenados al dominio financiero. Estudios posteriores han explorado el uso de modelos de lenguaje sobre titulares para anticipar reacciones del mercado. Estas evidencias justifican estudiar la señal textual, pero no permiten asumir que funcionará para cualquier activo, idioma o periodo.

Los backtests financieros presentan un riesgo particular de sobreajuste cuando se prueban muchas configuraciones y se conserva la mejor. Bailey y colaboradores formalizan este problema y resaltan la necesidad de validación fuera de muestra. Por ello, el proyecto definirá configuraciones antes de evaluar el periodo final y reportará resultados favorables y desfavorables.

2.2 Bases teóricas

2.2.1 Aprendizaje supervisado para dirección de mercado

La tarea se formula inicialmente como clasificación binaria. Para cada instante t , las características se calculan únicamente con información disponible hasta t . La etiqueta indica si el retorno del periodo t más h supera el umbral definido. Las observaciones cuyo futuro no está disponible se excluyen en lugar de etiquetarse como negativas.

La variable objetivo debe reflejar el horizonte operativo. Un cambio mínimo de precio puede no cubrir costos, por lo que se evaluará un umbral que incorpore comisiones y slippage. Como extensión, el estado abstenerse permite no operar cuando la probabilidad se encuentra cerca de la zona de incertidumbre.

2.2.2 Ingeniería de características

Las características iniciales incluirán retornos rezagados, medias móviles, volatilidad, rango verdadero, volumen relativo y medidas de momentum. Todas las transformaciones se calcularán de forma causal. Los parámetros de normalización se estimarán sobre la ventana de entrenamiento y se aplicarán sin recalcularlos con datos futuros.

2.2.3 XGBoost

XGBoost construye árboles secuenciales que corrigen errores residuales. El modelo optimiza una función objetivo compuesta por una pérdida y un término de regularización. Parámetros como profundidad, tasa de aprendizaje, número de árboles y subsampling controlan la complejidad. Su selección se realizará dentro de cada ventana de entrenamiento o mediante una ventana de validación previa.

2.2.4 Separación temporal y validación walk-forward

Una división aleatoria mezcla observaciones futuras con pasadas y puede producir estimaciones optimistas. La validación walk-forward entrena con un bloque histórico y evalúa el bloque siguiente, repitiendo el procedimiento a medida que avanza el tiempo. Esta estructura representa mejor el uso real del modelo y permite observar cambios de régimen.

2.2.5 Calibración probabilística

Una probabilidad calibrada significa que, entre las señales con valor cercano a 0,70, aproximadamente el 70 por ciento debería resultar favorable bajo condiciones comparables. Accuracy y AUC no garantizan esta propiedad. Se evaluarán Brier score, log loss y curvas de calibración; cuando corresponda, se aplicará calibración isotónica o sigmoideal usando datos separados del entrenamiento principal.

2.2.6 Análisis de sentimiento

El componente cualitativo recibirá titulares, fuente y fecha de publicación. Su salida mínima será un valor negativo, neutral o positivo, acompañado de un registro del modelo y del texto procesado. Los titulares publicados después del momento de decisión no podrán utilizarse en el backtest. La señal agregada considerará relevancia, duplicados y desacuerdo entre fuentes.

2.2.7 Arquitectura híbrida

La arquitectura separa estimación, contexto y decisión. XGBoost produce una probabilidad cuantitativa; el componente de lenguaje produce evidencia contextual; el árbitro combina ambas salidas mediante reglas explícitas. Esta separación facilita la auditoría y permite ejecutar experimentos de ablación sin modificar todo el sistema.

Componente	Entrada	Salida	Control principal
Pipeline de datos	OHLCV	Dataset validado	Calidad y orden temporal
Modelo XGBoost	Características	Probabilidad	Validación y calibración
Sentimiento	Titulares	Puntaje y evidencia	Fecha, fuente y relevancia
Árbitro	Probabilidad y sentimiento	Operar, no operar o abstenerse	Límites deterministas
Backtester	Señales y precios	Operaciones y métricas	Costos y ausencia de lookahead

2.2.8 Gestión de riesgo y criterio de Kelly

El criterio de Kelly relaciona la probabilidad de éxito con la relación entre ganancia y pérdida. Su forma básica es $f^* = (b p - q) / b$, donde p es la probabilidad de éxito, q es $1 - p$ y b es la ganancia neta por unidad arriesgada. Debido al error de estimación, el proyecto utilizará una fracción de Kelly y un límite independiente de exposición.

La asignación final también considerará stop loss, volatilidad, pérdida máxima por operación y drawdown acumulado. La política podrá reducir el tamaño o abstenerse. El modelo de lenguaje no podrá elevar la exposición por encima de estos límites.

2.2.9 Métricas de desempeño

Las métricas de clasificación describen la capacidad predictiva, mientras que las financieras describen el resultado de una estrategia. Accuracy, precision, recall y F1 se complementarán con Brier score y log loss. El backtest reportará retorno, volatilidad, Sharpe, Sortino, drawdown, win rate, profit factor, exposición, número de operaciones y sensibilidad a costos.

2.3 Definición de términos

Término	Definición operativa
Abstención	Decisión de no emitir una operación porque la evidencia o la calidad de datos es insuficiente.
Backtesting	Evaluación histórica de reglas definidas utilizando únicamente información disponible en cada momento.
Brier score	Promedio del error cuadrático entre probabilidades predichas y resultados binarios.
Calibración	Correspondencia entre probabilidades estimadas y frecuencias observadas.
Drawdown	Caída de una curva de capital desde un máximo previo hasta un mínimo posterior.
Feature engineering	Transformación causal de datos brutos en variables utilizadas por el modelo.
Lookahead bias	Uso accidental de información futura durante entrenamiento o simulación.
OHLCV	Datos de apertura, máximo, mínimo, cierre y volumen.
Paper trading	Simulación prospectiva de señales sin comprometer dinero real.
Profit factor	Relación entre ganancias brutas y pérdidas brutas.
Slippage	Diferencia entre el precio esperado y el precio simulado o ejecutado.
Walk-forward	Evaluación temporal repetida mediante ventanas sucesivas de entrenamiento y prueba.

Capítulo 3 Metodología

3.1 Tipo y diseño de investigación

La investigación será aplicada porque desarrollará un prototipo funcional; cuantitativa porque evaluará variables numéricas; experimental porque comparará configuraciones bajo condiciones definidas; y longitudinal porque respetará la secuencia temporal. El diseño será comparativo y utilizará experimentos de ablación para aislar el aporte de cada componente.

La unidad de análisis será una señal para un activo y fecha determinados. La unidad de evaluación financiera será una operación cerrada y, de forma agregada, la curva de capital de cada configuración. Los resultados se calcularán sobre ventanas fuera de muestra.

3.2 Arquitectura propuesta

El flujo se organiza en ocho etapas: adquisición, control de calidad, ingeniería de características, entrenamiento, calibración, análisis textual, arbitraje de riesgo y evaluación. Cada etapa generará un artefacto versionado o un registro auditable.

Etapas	Responsabilidad	Evidencia generada
Adquisición	Descargar precios y volumen	Fuente, activo y periodo
Calidad	Validar esquema y temporalidad	Reporte de validación
Features	Crear variables causales	Dataset y diccionario
Modelo	Entrenar XGBoost	Modelo y parámetros
Calibración	Ajustar probabilidades	Curva y Brier score
Sentimiento	Clasificar titulares	Puntaje, fuente y fecha
Árbitro	Aplicar reglas de riesgo	Decisión y justificación
Evaluación	Simular y comparar	Operaciones y métricas

3.3 Datos y variables

3.3.1 Datos de mercado

La primera versión utilizará precios diarios OHLCV de activos líquidos disponibles mediante una fuente pública. Para cada descarga se registrarán ticker, zona horaria, moneda, intervalo, fecha inicial, fecha final y momento de adquisición. Se detectarán duplicados, ausencias, precios no positivos y cambios de esquema.

3.3.2 Datos textuales

Los titulares se almacenarán con fuente, enlace, fecha de publicación y fecha de captura. Solo se utilizarán textos disponibles antes de la decisión. Se eliminarán duplicados y se

documentará la cobertura. Cuando no existan titulares válidos, el árbitro recibirá un estado de datos insuficientes en lugar de inventar una señal neutral.

3.3.3 Variable objetivo

La etiqueta se definirá como 1 cuando el retorno futuro del horizonte h supere un umbral operativo y 0 en caso contrario. Las últimas h observaciones no se etiquetarán. El umbral y horizonte se fijarán antes del periodo final de prueba y se analizará su sensibilidad.

3.3.4 Variables independientes

Las variables candidatas incluirán retornos rezagados, medias móviles, distancia respecto a medias, volatilidad, volumen relativo, rango de precios y momentum. La señal de sentimiento se incorporará únicamente en las configuraciones híbridas. La selección de variables se realizará sobre entrenamiento y validación.

3.4 Procedimiento experimental

Fase	Nombre	Actividad
Fase 1	Definición	Seleccionar activos, horizonte, frecuencia, costos, baselines y criterios de aceptación.
Fase 2	Datos	Descargar, validar y versionar datos de mercado y titulares.
Fase 3	Features	Construir variables y etiquetas causales; generar diccionario de datos.
Fase 4	Modelo	Entrenar XGBoost, seleccionar hiperparámetros y calibrar probabilidades.
Fase 5	Sentimiento	Clasificar titulares y validar formato, relevancia y temporalidad.
Fase 6	Riesgo	Aplicar reglas de abstención, límites y Kelly fraccional.
Fase 7	Backtesting	Ejecutar configuraciones comparables con costos y walk-forward.
Fase 8	Análisis	Comparar resultados, sensibilidad y amenazas a la validez.

3.5 Protocolo de evaluación

3.5.1 Configuraciones comparadas

Código	Configuración	Pregunta
B0	Buy and hold	¿El sistema supera una exposición pasiva?
B1	Regla técnica	¿XGBoost supera una regla simple?
M1	XGBoost	¿Existe señal cuantitativa fuera de muestra?
M2	XGBoost más sentimiento	¿El texto agrega información?
M3	M2 más árbitro	¿El riesgo mejora el perfil de pérdidas?

3.5.2 Validación temporal

Se utilizará un esquema walk-forward con una ventana inicial de entrenamiento, una ventana de validación para hiperparámetros y calibración, y una ventana de prueba posterior. La secuencia se desplazará hasta cubrir el periodo disponible. El conjunto final permanecerá sin consultar hasta congelar las decisiones metodológicas.

3.5.3 Costos y ejecución simulada

Cada operación incluirá una comisión y un slippage configurables. Las señales se ejecutarán en el siguiente precio disponible después de su generación. No se permitirá utilizar el cierre de una vela para producir y ejecutar una señal en ese mismo cierre. Las reglas de posición, salida y reinversión se documentarán antes de correr el periodo final.

3.5.4 Métricas

Grupo	Métrica	Interpretación
Clasificación	Precision y recall	Calidad de las señales positivas
Clasificación	F1	Balance entre precision y recall
Probabilidad	Brier score	Error de las probabilidades
Rentabilidad	Retorno anualizado	Crecimiento comparable por año
Riesgo	Máximo drawdown	Mayor pérdida desde un máximo
Riesgo ajustado	Sharpe y Sortino	Retorno frente a variabilidad y pérdidas
Operación	Profit factor	Ganancia bruta sobre pérdida bruta
Operación	Exposición	Tiempo y capital comprometidos

3.5.5 Criterios de interpretación

No se declarará superior una configuración por una sola métrica o ventana. Una mejora deberá aparecer en el periodo fuera de muestra, conservarse bajo costos razonables y no depender de una única operación. Se reportarán intervalos o dispersión entre ventanas cuando el tamaño de muestra lo permita.

3.6 Gestión de riesgo

El árbitro evaluará calidad de datos, probabilidad calibrada, sentimiento, relación ganancia pérdida y estado de la cuenta simulada. La decisión operar requerirá que todos los controles mínimos se cumplan. No operar corresponderá a una señal contraria o riesgo excesivo. Abstenerse corresponderá a incertidumbre, datos faltantes, degradación del modelo o desacuerdo sin evidencia suficiente.

Control	Regla inicial	Finalidad
Kelly	Usar fracción conservadora	Reducir sensibilidad al error de probabilidad
Exposición	Límite por activo	Evitar concentración
Pérdida	Riesgo máximo por operación	Controlar impacto individual
Drawdown	Pausa al superar el umbral	Evitar degradación acumulada
Datos	Abstenerse ante fallos	Impedir decisiones con información incompleta

3.7 Reproducibilidad y trazabilidad

Cada experimento almacenará identificador, versión de código, parámetros, periodo, variables, modelo, semilla, costos y métricas. Los datasets procesados tendrán versión y huella de integridad. Las decisiones conservarán la probabilidad, los titulares utilizados, el sentimiento, la regla aplicada y el resultado posterior.

- Entorno y dependencias declarados mediante archivo reproducible.
- Pruebas unitarias para etiquetas, métricas, Kelly y reglas del árbitro.
- Pruebas de integración con proveedores externos simulados.
- Registro de experimentos en una base SQLite durante la fase de prototipo.
- Separación entre datos crudos, procesados, modelos y resultados.

3.8 Consideraciones éticas y de seguridad

La investigación utilizará datos públicos y no intentará identificar o explotar información no pública. La interfaz y los informes indicarán que se trata de un prototipo experimental. No se conectará a cuentas reales durante el desarrollo. Las credenciales se mantendrán fuera del repositorio y las respuestas de proveedores se almacenarán respetando sus condiciones de uso.

3.9 Amenazas a la validez

Amenaza	Efecto posible	Mitigación
Lookahead	Resultados artificialmente altos	Causalidad de features y ejecución posterior
Sobreajuste	Configuración específica del periodo	Walk-forward y prueba final congelada
Sesgo de selección	Activos elegidos por resultados previos	Criterios de selección definidos antes
Noticias incompletas	Sentimiento poco representativo	Cobertura documentada y abstención
Cambios de régimen	Pérdida de estabilidad	Resultados por ventanas y paper trading
Costos estimados	Rentabilidad sobrevalorada	Análisis de sensibilidad

3.10 Productos y criterios de aceptación

Producto	Criterio de aceptación
Pipeline	Reproduce el dataset y genera reporte de calidad
Modelo	Entrena y evalúa sin usar datos futuros
Backtester	Incluye costos, slippage y reglas verificables
Comparación	Reporta B0, B1, M1, M2 y M3 bajo condiciones equivalentes
Trazabilidad	Permite reconstruir una decisión desde sus entradas
Informe	Presenta resultados favorables, desfavorables y limitaciones

3.11 Cronograma

Periodo	Trabajo
Meses 1 y 2	Alcance, revisión y protocolo
Meses 3 y 4	Datos y calidad
Meses 5 y 6	Features y XGBoost
Meses 7 y 8	Backtesting y validación
Meses 9 y 10	Sentimiento
Meses 11 y 12	Árbitro y riesgo
Meses 13 y 14	Ablaciones y sensibilidad
Meses 15 y 16	Paper trading y post-mortem
Meses 17 y 18	Análisis, documento y sustentación

Referencias bibliográficas

- [1] T. Chen and C. Guestrin, XGBoost A Scalable Tree Boosting System, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 785-794, 2016. DOI 10.1145/2939672.2939785.
- [2] S. Gu, B. Kelly and D. Xiu, Empirical Asset Pricing via Machine Learning, The Review of Financial Studies, vol. 33, no. 5, pp. 2223-2273, 2020. DOI 10.1093/rfs/hhaa009.
- [3] A. Lopez-Lira and Y. Tang, Can ChatGPT Forecast Stock Price Movements Return Predictability and Large Language Models, arXiv 2304.07619, 2023.

- [4] D. Araci, FinBERT Financial Sentiment Analysis with Pre-trained Language Models, arXiv 1908.10063, 2019.
- [5] C. Guo, G. Pleiss, Y. Sun and K. Q. Weinberger, On Calibration of Modern Neural Networks, Proceedings of Machine Learning Research, vol. 70, pp. 1321-1330, 2017.
- [6] D. H. Bailey, J. M. Borwein, M. López de Prado and Q. J. Zhu, The Probability of Backtest Overfitting, Journal of Computational Finance, vol. 20, no. 4, 2017.
- [7] J. L. Kelly Jr., A New Interpretation of Information Rate, Bell System Technical Journal, vol. 35, no. 4, pp. 917-926, 1956. DOI 10.1002/j.1538-7305.1956.tb03809.x.
- [8] W. F. Sharpe, The Sharpe Ratio, The Journal of Portfolio Management, vol. 21, no. 1, pp. 49-58, 1994. DOI 10.3905/jpm.1994.409501.
- [9] B. M. Barber, Y. T. Lee, Y. J. Liu and T. Odean, Just How Much Do Individual Investors Lose by Trading, The Review of Financial Studies, vol. 22, no. 2, pp. 609-632, 2009.
- [10] B. M. Barber, X. Huang, T. Odean and C. Schwarz, Attention-Induced Trading and Returns Evidence from Robinhood Users, The Journal of Finance, vol. 77, no. 6, pp. 3141-3190, 2022.
- [11] F. Pedregosa et al., Scikit-learn Machine Learning in Python, Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
- [12] P. Virtanen et al., SciPy 1.0 Fundamental Algorithms for Scientific Computing in Python, Nature Methods, vol. 17, pp. 261-272, 2020.