

CORPORACIÓN UNIVERSITARIA MINUTO DE DIOS

Ingeniería de Sistemas

Semillero de Investigación Sophia

**Desarrollo y evaluación de una arquitectura híbrida basada
en XGBoost y modelos de lenguaje para apoyar decisiones de
trading y gestión de riesgo en mercados volátiles**

Propuesta de investigación reformulada

Dorian Joseph Esguerra Perilla
Código estudiantil 831244

Kevin Daniel Arango Algarra
Código estudiantil 751148

Director Carlos Armando López Solano MSc

Bogotá 2026

Identificación de la propuesta

Campo	Información
Programa	Ingeniería de Sistemas
Área	Inteligencia artificial y ciencia de datos
Línea	Innovaciones sociales y productivas
Proponentes	Dorian Joseph Esguerra Perilla y Kevin Daniel Arango Algarra
Director	Carlos Armando López Solano MSc
Producto principal	Prototipo experimental reproducible y evaluación comparativa

Resumen de la propuesta

Esta investigación propone desarrollar y evaluar una arquitectura híbrida para apoyar decisiones de trading en mercados volátiles. El sistema combinará un modelo XGBoost entrenado con datos históricos de mercado, un componente de análisis de sentimiento aplicado a titulares financieros y un módulo determinista de gestión de riesgo. La investigación no parte de una tasa de acierto esperada ni busca demostrar rentabilidad garantizada. Su propósito es medir, mediante un protocolo reproducible, si cada componente agrega valor frente a líneas base sencillas y frente al modelo exclusivamente cuantitativo.

La evaluación utilizará separación temporal, validación walk-forward y backtesting con costos de transacción y slippage. Se reportarán métricas de clasificación, calibración probabilística y desempeño financiero. El resultado será un prototipo orientado a investigación y simulación. La ejecución con dinero real, la conexión con brokers y la detección de información no pública quedan fuera del alcance.

Antecedentes y justificación

Los inversores minoristas toman decisiones en entornos con alta incertidumbre, cambios de régimen y abundancia de información. Los modelos de aprendizaje automático pueden capturar relaciones no lineales entre variables de mercado, pero su utilidad depende de una evaluación fuera de muestra y de controles contra el sobreajuste. XGBoost ofrece un enfoque adecuado para construir una línea base cuantitativa porque combina árboles de decisión, regularización y capacidad para representar interacciones no lineales.

Las noticias financieras contienen información contextual que no siempre está representada en las series OHLCV. Los modelos de lenguaje permiten transformar titulares en variables de sentimiento; sin embargo, sus resultados deben tratarse como evidencia auxiliar y no como una probabilidad de éxito. La investigación evaluará el aporte incremental del sentimiento mediante experimentos de ablación, en vez de asumir que su incorporación mejora el desempeño.

La contribución práctica consiste en integrar datos, modelo, contexto textual y gestión de riesgo dentro de un flujo auditable. La contribución académica consiste en comparar configuraciones controladas bajo el mismo conjunto de datos, horizonte y costos, con énfasis en reproducibilidad y análisis de limitaciones.

Planteamiento del problema

Una señal predictiva puede presentar precisión aceptable y aun así producir una estrategia poco rentable por efecto de costos, desbalance de clases, probabilidades mal calibradas o pérdidas concentradas. A la vez, agregar noticias o modelos de lenguaje puede aumentar la complejidad sin aportar mejora fuera de muestra. El problema de investigación es determinar si una arquitectura híbrida ofrece un beneficio medible frente a alternativas más simples cuando se evalúa con separación temporal y métricas financieras.

Pregunta de investigación

¿En qué medida la integración de un modelo XGBoost, una señal de sentimiento derivada de titulares financieros y una política determinista de gestión de riesgo mejora el desempeño fuera de muestra frente a un modelo exclusivamente cuantitativo y frente a estrategias de referencia en mercados volátiles?

Objetivos

Objetivo general

Desarrollar y evaluar una arquitectura híbrida basada en XGBoost, análisis de sentimiento y gestión probabilística de riesgo para apoyar decisiones de trading en mercados volátiles mediante experimentos reproducibles y backtesting temporal.

Objetivos específicos

- Construir un pipeline reproducible para obtener, validar y transformar datos históricos OHLCV.
- Diseñar características técnicas sin utilizar información futura y entrenar un modelo XGBoost como línea base cuantitativa.
- Transformar titulares financieros en una señal de sentimiento con salida estructurada y trazable.
- Diseñar un árbitro determinista que combine probabilidad calibrada, sentimiento y límites de riesgo para decidir operar, no operar o abstenerse.
- Implementar backtesting walk-forward con costos de transacción, slippage y reglas explícitas de entrada y salida.
- Comparar configuraciones mediante métricas de clasificación, calibración y desempeño financiero, e identificar el aporte incremental de cada componente.

Hipótesis

Hipótesis de investigación H1. La arquitectura híbrida produce una mejora fuera de muestra en al menos una métrica financiera ajustada por riesgo, sin empeorar de forma material el drawdown máximo, frente al modelo exclusivamente cuantitativo.

Hipótesis nula H0. La incorporación del sentimiento y del árbitro de riesgo no produce una mejora consistente frente al modelo cuantitativo bajo el mismo periodo, costos y reglas de evaluación.

Las hipótesis se analizarán sobre múltiples ventanas temporales. No se establecerá una tasa de acierto como resultado obligatorio. La interpretación considerará estabilidad, magnitud del efecto y sensibilidad a costos.

Alcance y delimitaciones

Incluido	Fuera del alcance
Datos OHLCV e indicadores técnicos	Ejecución de órdenes con dinero real
XGBoost y calibración probabilística	Garantías de rentabilidad o recomendaciones personalizadas
Sentimiento de titulares financieros	Detección de información no pública o insider trading
Backtesting y paper trading	Alta frecuencia y arbitraje de latencia
Gestión de riesgo determinista	Optimización de portafolios institucionales

Metodología

La investigación será aplicada, cuantitativa, experimental y comparativa. La unidad de análisis será una señal generada para un activo y horizonte definidos. Los experimentos conservarán el orden temporal de los datos. Los hiperparámetros y umbrales se ajustarán únicamente con información previa al periodo evaluado.

Diseño experimental

Configuración	Componentes	Propósito
B0	Buy and hold	Referencia de mercado
B1	Regla técnica simple	Referencia no basada en aprendizaje automático
M1	XGBoost	Línea base cuantitativa
M2	XGBoost más sentimiento	Medir aporte del contexto textual
M3	XGBoost más sentimiento más árbitro	Medir aporte de la gestión de riesgo

Variables y métricas

Dimensión	Métricas
Clasificación	Accuracy, precision, recall, F1 y matriz de confusión
Probabilidad	Brier score, curva de calibración y log loss
Rentabilidad	Retorno total, retorno anualizado y retorno por operación
Riesgo	Volatilidad, máximo drawdown, Sharpe y Sortino
Operación	Win rate, profit factor, número de operaciones y exposición
Robustez	Sensibilidad a costos, ventanas, activos y umbrales

Procedimiento

1. Definir activos, frecuencia, horizonte de predicción y periodo de observación.
2. Descargar y validar datos; normalizar fechas, zonas horarias, duplicados y valores faltantes.
3. Construir características técnicas y la variable objetivo sin etiquetar observaciones cuyo futuro sea desconocido.
4. Aplicar división temporal y validación walk-forward.
5. Entrenar, calibrar y evaluar XGBoost.
6. Procesar titulares disponibles antes de cada decisión y conservar fuente, fecha y resultado del análisis.
7. Ejecutar las configuraciones B0, B1, M1, M2 y M3 bajo costos equivalentes.
8. Analizar resultados, estabilidad, limitaciones y amenazas a la validez.

Gestión de riesgo

El tamaño de posición se calculará con una variante fraccional del criterio de Kelly. La probabilidad utilizada deberá estar calibrada y la asignación estará restringida por límites de exposición, pérdida por operación y drawdown. El componente textual podrá reducir o vetar una operación, pero no aumentar por sí solo el riesgo por encima de los límites cuantitativos.

Resultados esperados y entregables

- Repositorio reproducible con configuración, código y pruebas automatizadas.
- Dataset procesado con diccionario de variables y registro de procedencia.
- Modelo base, modelo híbrido y política de riesgo versionados.
- Motor de backtesting con costos y validación walk-forward.
- Informe comparativo con métricas, curvas de capital y análisis de sensibilidad.
- Prototipo de consulta de experimentos y resultados, sin conexión a un broker real.

Cronograma

Periodo	Actividad principal	Entregable
Meses 1 y 2	Revisión, alcance y protocolo experimental	Diseño de investigación aprobado
Meses 3 y 4	Pipeline y control de calidad de datos	Dataset reproducible
Meses 5 y 6	Features y modelo XGBoost	Línea base cuantitativa
Meses 7 y 8	Backtesting y validación walk-forward	Motor de evaluación
Meses 9 y 10	Sentimiento y trazabilidad de noticias	Modelo híbrido M2
Meses 11 y 12	Árbitro y gestión de riesgo	Configuración M3
Meses 13 y 14	Experimentos, ablaciones y sensibilidad	Resultados comparativos
Meses 15 y 16	Paper trading y post-mortem	Validación operativa simulada
Meses 17 y 18	Análisis, redacción y sustentación	Documento final

Consideraciones éticas y de seguridad

El sistema se presentará como herramienta experimental y no como asesor financiero. Los resultados históricos no se interpretarán como garantía de desempeño futuro. La investigación documentará fallos, sesgos, cobertura limitada de noticias y dependencia de proveedores externos. No se procesará información privada ni se afirmará acceso a información privilegiada. Cualquier fase de paper trading permanecerá separada de cuentas con dinero real.

Limitaciones previstas

- Cambios de régimen que reducen la estabilidad de patrones históricos.
- Disponibilidad y calidad variables de titulares financieros.
- Riesgo de sobreajuste por selección repetida de hiperparámetros.
- Probabilidades del clasificador que requieren calibración fuera de muestra.
- Resultados sensibles a costos, frecuencia, activo y horizonte de inversión.

Referencias bibliográficas

- [1] T. Chen and C. Guestrin, XGBoost A Scalable Tree Boosting System, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 785-794, 2016. DOI 10.1145/2939672.2939785.
- [2] S. Gu, B. Kelly and D. Xiu, Empirical Asset Pricing via Machine Learning, The Review of Financial Studies, vol. 33, no. 5, pp. 2223-2273, 2020. DOI 10.1093/rfs/hhaa009.
- [3] A. Lopez-Lira and Y. Tang, Can ChatGPT Forecast Stock Price Movements Return Predictability and Large Language Models, arXiv 2304.07619, 2023.
- [4] D. Araci, FinBERT Financial Sentiment Analysis with Pre-trained Language Models, arXiv 1908.10063, 2019.
- [5] C. Guo, G. Pleiss, Y. Sun and K. Q. Weinberger, On Calibration of Modern Neural Networks, Proceedings of Machine Learning Research, vol. 70, pp. 1321-1330, 2017.
- [6] D. H. Bailey, J. M. Borwein, M. López de Prado and Q. J. Zhu, The Probability of Backtest Overfitting, Journal of Computational Finance, vol. 20, no. 4, 2017.
- [7] J. L. Kelly Jr., A New Interpretation of Information Rate, Bell System Technical Journal, vol. 35, no. 4, pp. 917-926, 1956. DOI 10.1002/j.1538-7305.1956.tb03809.x.
- [8] W. F. Sharpe, The Sharpe Ratio, The Journal of Portfolio Management, vol. 21, no. 1, pp. 49-58, 1994. DOI 10.3905/jpm.1994.409501.
- [9] B. M. Barber, Y. T. Lee, Y. J. Liu and T. Odean, Just How Much Do Individual Investors Lose by Trading, The Review of Financial Studies, vol. 22, no. 2, pp. 609-632, 2009.
- [10] B. M. Barber, X. Huang, T. Odean and C. Schwarz, Attention-Induced Trading and Returns Evidence from Robinhood Users, The Journal of Finance, vol. 77, no. 6, pp. 3141-3190, 2022.
- [11] F. Pedregosa et al., Scikit-learn Machine Learning in Python, Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
- [12] P. Virtanen et al., SciPy 1.0 Fundamental Algorithms for Scientific Computing in Python, Nature Methods, vol. 17, pp. 261-272, 2020.